

Metody Inteligencji Obliczeniowej

Sprawozdanie 6



Wydział Fizyki i Informatyki Stosowanej

Mikhail Shupliakou

07.05.2026

Spis treści

1	Wstęp teoretyczny	3
2	Zadanie 1	3
2.1	Cel i zakres zadania	3
2.2	Proces wykonania zadania	3
2.3	Przygotowanie danych	3
2.4	Wyznaczenie optymalnej liczby klastrów	3
2.5	Modelowanie i wizualizacja	4
2.6	Wnioski z wizualizacji	4
3	Zadanie 2	5
3.1	Cel i zakres zadania	5
3.2	Proces realizacji zadania	5
3.3	Przygotowanie danych i inżynieria cech	5
3.4	Implementacja algorytmów klasteryzacji	6
3.5	Metryki jakości i walidacja	6
3.6	Redukcja wymiarowości i wizualizacja	6
3.7	Analiza metryk jakości	7
3.8	Charakterystyka fizyczna klastrów (model K-Means)	7
3.9	Wnioski końcowe	8
4	Zadanie 3	8
4.1	Cel i zakres zadania	8
4.2	Metodyka i przebieg prac	8
4.3	Wnioski i podsumowanie	8
4.4	Efektywność algorytmów a topologia danych	9
4.5	Paradoks metryk jakości	9
4.6	Interpretacja wskaźnika ARI	10

Klasteryzacja

1 Wstęp teoretyczny

Klasteryzacja, znana również jako analiza skupień (ang. *clustering*), jest jedną z najważniejszych technik uczenia nienadzorowanego (ang. *unsupervised learning*). Głównym celem tego procesu jest podział zbioru danych na grupy (klastry) w taki sposób, aby obiekty wewnątrz tej samej grupy były do siebie jak najbardziej podobne, natomiast obiekty należące do różnych grup — jak najbardziej zróżnicowane.

W przeciwieństwie do klasyfikacji, klasteryzacja nie wymaga wcześniejszej znajomości etykiet czy przynależności obiektów do konkretnych klas. Algorytmy klasteryzacji operują na miarach podobieństwa, które najczęściej definiuje się jako odległość w wielowymiarowej przestrzeni cech (np. odległość euklidesowa). Proces ten pozwala na odkrycie ukrytej struktury danych, co znajduje szerokie zastosowanie w segmentacji klientów, analizie obrazów oraz eksploracji danych medycznych.

2 Zadanie 1

2.1 Cel i zakres zadania

Celem niniejszego zadania jest przeprowadzenie segmentacji bazy klientów centrum handlowego w celu zidentyfikowania naturalnych grup konsumentów o podobnych profilach ekonomicznych. Analiza została oparta na zbiorze danych `customers_mall.csv`, zawierającym informacje o rocznych zarobkach klientów (w tysiącach) oraz ich punktowej ocenie wydatków (w skali 0–100).

2.2 Proces wykonania zadania

Proces analizy danych i segmentacji klientów został podzielony na trzy główne etapy: przygotowanie danych, wyznaczenie optymalnej liczby klastrów oraz finalną klasteryzację wraz z interpretacją wyników.

2.3 Przygotowanie danych

W pierwszym kroku dane zostały wczytane z pliku `customers_mall.csv`. Do analizy wybrano kolumny dotyczące rocznego dochodu oraz oceny wydatków. Dane zostały przekształcone do macierzy NumPy, co jest wymagane przez bibliotekę `scikit-learn`.


```
df = pd.read_csv('customers_mall.csv', sep=';')
X = df.values # Macierz cech: dochód i ocena wydatków
```

2.4 Wyznaczenie optymalnej liczby klastrów

Aby uniknąć subiektywnego wyboru liczby grup, zastosowano metodę:

Analiza współczynnika sylwetki (Silhouette Score) – oceniająca jakość separacji klastrów.

```
# Analiza Silhouette Score
sil_scores = []
for i in range(2, 11):
    kmeans = KMeans(n_clusters=i, init='k-means++', random_state=42)
    labels = kmeans.fit_predict(X)
    sil_scores.append(silhouette_score(X, labels))
```



Wykres przedstawia wartości współczynnika sylwetki w zależności od liczby klastrów k . Metoda ta służy do oceny jakości klasteryzacji poprzez pomiar tego, jak bardzo dany obiekt jest podobny do swojego klastra w porównaniu z innymi grupami. Współczynnik ten przyjmuje wartości z zakresu od -1 do 1.

Wyższe wartości wskazują na to, że obiekty są dobrze dopasowane do swoich klastrów i wyraźnie odseparowane od sąsiednich skupień. Na zaprezentowanym wykresie można zauważyć, że najwyższy wynik osiągnięto dla wartości $k = 5$. Jest to kluczowy wskaźnik, który w połączeniu z metodą łokcia pozwala jednoznacznie zarekomendować podział bazy klientów na pięć segmentów jako najbardziej stabilny i poprawny matematycznie.

2.5 Modelowanie i wizualizacja

Na podstawie przeprowadzonych testów (wyraźne załamanie wykresu łokcia oraz wysoki wynik Silhouette dla $k = 5$) dokonano ostatecznego podziału danych. Wykorzystano algorytm KMeans z inicjalizacją k-means++, która zapewnia lepszą zbieżność.


```
k_optimal = 5
kmeans = KMeans(n_clusters=k_optimal, init='k-means++', random_state=42)
y_kmeans = kmeans.fit_predict(X)

# Centroidy - srodki ciężkości klastrów
centroids = kmeans.cluster_centers_
```

2.6 Wnioski z wizualizacji

Wynikiem działania algorytmu jest podział przestrzeni na 5 segmentów. Na wykresie końcowym każdy klaster został oznaczony innym kolorem, a żółte gwiazdki

reprezentują *centroidy* (punkty centralne grup). Taki podział pozwala zidentyfikować kluczowe grupy klientów, m.in. grupę VIP (wysokie dochody, wysokie wydatki) oraz grupę oszczędną.



3 Zadanie 2

3.1 Cel i zakres zadania

Celem niniejszego zadania jest analiza zbioru danych zawierającego parametry 778 planet pozasłonecznych (egzoplanet) pochodzących z bazy danych NASA. Zadanie polega na wykorzystaniu technik uczenia nienadzorowanego do automatycznej identyfikacji grup obiektów o zbliżonych charakterystykach fizycznych i orbitalnych.

3.2 Proces realizacji zadania

Eksperyment polegał na automatycznej segmentacji zbioru danych astronomicznych `planets.csv` przy użyciu trzech zróżnicowanych paradygmatów klasteryzacji. Poniżej przedstawiono szczegółowy opis etapów prac.

3.3 Przygotowanie danych i inżynieria cech

W pierwszej kolejności dokonano selekcji 9 kluczowych cech numerycznych opisujących właściwości fizyczne planet (promień, masa, temperatura) oraz ich gwiazd macierzystych. Ze względu na wrażliwość algorytmów na brakujące dane oraz różnice w skalach wielkości, przeprowadzono proces czyszczenia i standaryzacji.

```
# Wybór cech i usunięcie rekordów z brakami (NaN)
features = ['pl_orbper', 'pl_orbsmax', 'pl_rade', 'pl_masse', 'pl_orbeccen',
            'pl_eqt', 'st_teff', 'st_mass', 'sy_dist']
X = df[features].dropna()

# Standaryzacja przy użyciu StandardScaler
scaler = StandardScaler()
X_scaled = scaler.fit_transform(X)
```

3.4 Implementacja algorytmów klasteryzacji

Zgodnie z materiałami laboratoryjnymi, do analizy wybrano trzy metody o różnej charakterystyce matematycznej:

- **K-Means:** Algorytm podziałowy dążący do minimalizacji inercji wewnątrz grup. Przyjęto liczbę klastrow $k = 3$.
- **Agglomerative Clustering:** Podejście hierarchiczne, łączące obiekty w sposób aglomeracyjny.
- **DBSCAN:** Algorytm gęstościowy, zdolny do wykrywania klastrow o dowolnych kształtach oraz identyfikacji punktów odstających (szumu).

```
# K-Means (k=3)
kmeans = KMeans(n_clusters=3, random_state=42, n_init=10)
results['K-Means'] = kmeans.fit_predict(X_scaled)

# DBSCAN (gestosciowy)
dbscan = DBSCAN(eps=1.5, min_samples=5)
results['DBSCAN'] = dbscan.fit_predict(X_scaled)
```

3.5 Metryki jakości i walidacja


Do oceny uzyskanych wyników zastosowano trzy metryki wewnętrzne. Szczególną uwagę poświęcono algorytmowi DBSCAN — przy obliczaniu metryk zaimplementowano maskowanie punktów uznanych za szum (oznaczonych etykietą -1), aby uniknąć zafałszowania wyników spójności klastrow.

- **Silhouette Score:** Ocena spójności i separacji.
- **Davies-Bouldin Index:** Miara bazująca na stosunku rozproszenia wewnątrz klastrow do odległości między nimi.
- **Calinski-Harabasz Index:** Stosunek dyspersji międzyklastrowej do wewnętrz-klastrowej.

3.6 Redukcja wymiarowości i wizualizacja

Dane o 9 wymiarach zostały zredukowane do 2 głównych składowych przy użyciu metody PCA (*Principal Component Analysis*), co umożliwiło wizualną ocenę granic decyzyjnych algorytmów na płaszczyźnie.

```
pca = PCA(n_components=2)
X_pca = pca.fit_transform(X_scaled)
```



3.7 Analiza metryk jakości

--- Wyniki metryk ---				
	Metoda	Silhouette	Davies-Bouldin	Caliski-Harabasz
0	K-Means	0.313778	1.019299	273.549319
1	Agglomerative	0.288482	0.900943	246.329464
2	DBSCAN	NaN	NaN	NaN

Porównanie algorytmów na podstawie metryk wewnętrznych pozwala na wyciągnięcie następujących wniosków:

- **K-Means** uzyskał najwyższy współczynnik sylwetki (0.314) oraz najwyższy indeks Calińskiego-Harabasza (273.5), co sugeruje, że ten model najlepiej radzi sobie z odseparowaniem zwartych grup w tej przestrzeni cech.
- **Agglomerative Clustering** wykazał nieco lepszy (niższy) wynik indeksu Daviesa-Bouldina (0.901), co świadczy o dobrej zwartości wewnątrzklustrowej.
- **DBSCAN** zwrócił wartości *NaN*. Wynika to z faktu, że przy dobranych parametrach (*eps*, *min_samples*) algorytm prawdopodobnie zaklasyfikował wszystkie punkty jako szum lub wyodrębnił tylko jeden klaster, co uniemożliwia obliczenie metryk separacji.

3.8 Charakterystyka fizyczna klastrów (model K-Means)

Na podstawie średnich wartości parametrów fizycznych dla $k = 3$, wyodrębniono następujące typy systemów planetarnych:

1. **Klaster 0 (Zimne olbrzymy):** Charakteryzuje się bardzo długim okresem orbitalnym (≈ 1689 dni) i dużą odległością od gwiazdy (2.61 AU). Są to planety masywne o niskiej temperaturze równowagi (194 K), krążące wokół gwiazd o masie zbliżonej do Słońca.
2. **Klaster 1 (Gorące olbrzymy/Jowisze):** Obejmuje planety o bardzo krótkim okresie orbitalnym (≈ 7.9 dni) i wysokiej temperaturze (1552 K). Krążą one wokół masywnych gorących gwiazd (6023 K). Są to obiekty o największym promieniu w całym zbiorze.
3. **Klaster 2 (Planety skaliste i Super-Ziemia):** Grupa planet o najmniejszej masie i promieniu, krążących wokół mniejszych i chłodniejszych gwiazd typu M lub K (4719 K). Znajdują się one relatywnie blisko Ziemi (średni dystans 130 pc).

3.9 Wnioski końcowe

Algorytm K-Means pozwolił na sensowną z punktu widzenia astronomii segmentację danych, dzieląc egzoplanety na grupy odpowiadające ich fizycznej naturze (od zimnych gazowych olbrzymów po mniejsze planety wokół chłodnych gwiazd). Niskie wartości współczynnika Silhouette dla wszystkich metod wskazują jednak na to, że parametry planet pozasłonecznych tworzą kontinuum, a granice między ich typami nie są ostro zarysowane w naturze.

4 Zadanie 3

4.1 Cel i zakres zadania

Celem niniejszego zadania jest weryfikacja skuteczności poznanych algorytmów klasteryzacji w przypadku zbioru danych o nieliniowej i niewypukłej strukturze geometrycznej (*non-convex*). Analiza koncentruje się na porównaniu zdolności różnych modeli — od metod opartych na centroidach (K-średnich), przez metody hierarchiczne, aż po algorytmy gęstościowe (DBSCAN) — do poprawnej separacji dwóch koncentrycznych okręgów. Istotnym elementem badania jest krytyczna ocena uzyskanych wyników za pomocą dedykowanych metryk jakości oraz wskazanie przyczyn, dla których niektóre algorytmy, mimo dobrych wskaźników matematycznych, zawiodą w poprawnej interpretacji topologii tego specyficznego zbioru danych.


4.2 Metodyka i przebieg prac

Proces realizacji zadania koncentrował się na wieloaspektowym porównaniu różnych paradygmatów klasteryzacji. Po wstępnym przygotowaniu danych i ich standaryzacji, co jest kluczowe dla metod opartych na miarach odległości, zaimplementowano algorytmy reprezentujące odmienne podejścia matematyczne: K-średnich (podejście centroidalne), klasteryzację hierarchiczną (wiązania aglomeracyjne) oraz DBSCAN (podejście gęstościowe). Wykorzystanie tak szerokiego spektrum metod miało na celu sprawdzenie, jak poszczególne modele radzą sobie z identyfikacją struktur o specyficznej charakterystyce geometrycznej.

W celu obiektywnej oceny uzyskanych wyników zastosowano zestaw zróżnicowanych metryk jakości, takich jak współczynnik sylwetki (Silhouette Score), indeks Daviesa-Bouldina oraz indeks Calińskiego-Harabasza. Takie podejście pozwoliło na wielokryterialną analizę spójności i separacji klastrów. Dodatkowo, za pomocą indeksu ARI (Adjusted Rand Index), zweryfikowano stopień zgodności między wynikami algorytmów operujących na różnych założeniach (np. geometrycznym vs gęstościowym). Ostateczna weryfikacja opierała się na zestawieniu wartości numerycznych z wizualizacjami, co pozwoliło na wybór modelu najlepiej oddającego rzeczywistą strukturę zbioru danych.

4.3 Wnioski i podsumowanie

Analiza porównawcza wyników klasteryzacji dla zbioru `circle.csv` pozwala na sformułowanie kluczowych spostrzeżeń dotyczących natury algorytmów oraz adekwatności stosowanych metryk oceny.



4.4 Efektywność algorytmów a topologia danych

Zbiór danych w kształcie dwóch koncentrycznych okręgów jest przykładem struktury niewypukłej (*non-convex*), co stanowi fundamentalne wyzwanie dla większości klasycznych metod:

- **Zwycięzcy (DBSCAN oraz Agglomerative Single Linkage):** Choć ich metryki matematyczne są niskie, to właśnie te algorytmy poprawnie zidentyfikowały dwa pierścienie. Wynika to z faktu, że bazują one na **gęstości i powiązaniach lokalnych** punktów, co pozwala na śledzenie nieliniowych kształtów.
- **Przegrani (K-Means oraz Agglomerative Ward Linkage):** Algorytmy te "rozcięły" okręgi na pół, tworząc dwa zwarte półksiężyce. Dzieje się tak, ponieważ dążą one do minimalizacji wariancji i tworzenia klastrów sferycznych (wypukłych).

4.5 Paradoks metryk jakości

--- Tabela metryk jakości klasteryzacji ---

Algorytm	Silhouette	Davies-Bouldin	Calinski-Harabasz
K-Means	0.352676	1.185771	572.324683
Agglomerative (Single)	0.113872	170.760374	0.030709
Agglomerative (Ward)	0.338058	1.217078	532.609314
DBSCAN	0.113872	170.760374	0.030709

Adjusted Rand Index (K-Means vs DBSCAN): -0.0009
Warto ARI bliska 0 oznacza brak istotnej zgodności między tymi podziałami.

Tabela metryk ukazuje zjawisko, które może być mylące przy bezkrytycznej analizie danych:

- Metryki takie jak **Silhouette Score** czy **Calinski-Harabasz Index** wykazują znacznie lepsze wartości dla algorytmu *K-Means*.
- **Przyczyna:** Metryki te wewnętrznie zakładają, że idealny klaster to gęsta, wypukła "kula". Ponieważ okręgi są rozciągnięte i puste w środku, metryki te karzą poprawne rozwiązanie (DBSCAN) za brak "zwartości" i nagradzają błędne rozwiązanie (K-Means) za stworzenie dwóch zbitych grup.
- **Wniosek:** W przypadku struktur nieliniowych, tradycyjne metryki wewnętrzne nie są wiarygodnym wskaźnikiem poprawności modelu.

4.6 Interpretacja wskaźnika ARI

Wartość **Adjusted Rand Index (ARI)** wynosząca około -0.0009 (praktycznie zero) jest ostatecznym dowodem na to, że algorytmy *K-Means* i *DBSCAN* dokonały zupełnie innych podziałów. Zerowa zgodność potwierdza, że podejście oparte na odległości od środka masy (centroidu) jest całkowicie niekompatybilne z podejściem opartym na łączności punktów w tym konkretnym zbiorze danych.

Podsumowanie końcowe: Eksperyment dowiódł, że wybór algorytmu musi być podyktowany wstępną wizualizacją danych. Dla danych o złożonej geometrii, metody gęstościowe (DBSCAN) lub powiązaniowe (*Single Linkage*) są bezalternatywne, nawet jeśli ich formalne wskaźniki jakości wydają się mniej korzystne niż w przypadku metod tradycyjnych.